

Universidad Internacional de La Rioja

Facultad de Ingeniería y Tecnología

Máster Universitario en Análisis y Visualización de Datos Masivos / Visual Analitics & Big Data

Actividad HDFS, Spark SQL y MLlib

Actividad de estudio presentado por:	Juan David Escobar Escobar
Tipo de trabajo:	Actividad
Modalidad:	Individual
Profesor/a:	Dr. Pablo J. Villacorta
Fecha:	Enero 2022

Comando creación de clúster de Spark mediante Google Shell:

gcloud beta dataproc clusters create cluster-jde --enable-component-gateway --bucket jde_procesado_datos_masivos_act_1 --region europe-west1 --zone europe-west1-c -- master-machine-type n1-standard-1 --master-boot-disk-size 500 --num-workers 2 -- worker-machine-type n1-standard-1 --worker-boot-disk-size 500 --image-version 1.4-debian10 --properties spark:spark.jars.packages=org.apache.spark:spark-sql-kafka-o-10_2.11:2.4.0 --optional-components ANACONDA,JUPYTER,ZOOKEEPER --max-age 14400s --initialization-actions 'gs://goog-dataproc-initialization-actions-europe-west1/kafka/kafka.sh' --project neon-mesh-333522

```
And introduction has each military and the dates of client many factors of consequence of conseq
```

Comandos HDFS

- hadoop fs -mkdir /juan_escobar_escobar
- hadoop fs -ls /
- hdfs dfs -copyFromLocal /flights_act1.csv /juan_escobar_escobar
- hadoop fs -ls /juan_escobar_escobar

```
Terminal 2
root@cluster-jde-m:/# hadoop fs -mkdir /juan_escobar_escobar
root@cluster-jde-m:/# ls
bin boot dev etc flights_act1.csv hadoop home lib lib32 lib64 libx32 lost+found media mnt
root@cluster-jde-m:/# hadoop fs -ls /
Found 5 items
              mapred hadoop
                                     0 2022-01-13 00:09 /hadoop
drwxrwxrwt
                                     0 2022-01-13 00:22 /juan_escobar_escobar
drwxr-xr-x

    root hadoop

              mapred hadoop
                                     0 2022-01-13 00:09 /tmp
drwxrwxrwt
drwxrwxrwt
                                     0 2022-01-13 00:09 /user
              hdfs
                     hadoop
              hive
                     hadoop
                                     0 2022-01-13 00:10 /var
root@cluster-jde-m:/# hdfs dfs -copyFromLocal /flights_act1.csv /juan_escobar_escobar
root@cluster-jde-m:/# hadoop fs -ls /juan_escobar_escobar
Found 1 items
                            11244080 2022-01-13 00:23 /juan_escobar_escobar/flights_act1.csv
            2 root hadoop
root@cluster-jde-m:/#
```

Se hace referencia a los recursos utilizados para el desarrollo de la actividad en el siguiente repositorio de <u>GitHub</u>

Herramientas:

- Jupyter Nootebooks Versión (v2.4.8),
- Python (Python 3.6.13 :: Anaconda, Inc)

Librerías y Módulos:

- Spark v2.4.8
- pyspark.sql.functions
- pyspark.ml.feature

- pyspark.ml.classification
- pyspark.ml.